

Segmentación de caries en radiografías panorámicas dentales mediante redes neuronales convolucionales

Sonia Torres Ibarra

Matrícula: 1563824

Maestría en Ciencia de Datos — Procesamiento y Clasificación de Datos

Introducción

Las caries dentales son una de las patologías más frecuentes en odontología. Su identificación manual en radiografías panorámicas es lenta y depende de la experiencia del especialista. Este trabajo propone un modelo de **segmentación semántica basado en CNN** para delimitar automáticamente las regiones con caries, aportando información espacial precisa en lugar de una simple etiqueta de clasificación.


Objetivo

Disenar, entrenar y evaluar una red neuronal convolucional capaz de segmentar regiones con caries en radiografas panoramicas dentales, aplicando *transfer learning* y *fine-tuning*

Conjunto de datos

Dataset público **MLUA** (Wang et al., 2023), con radiografías panorámicas dentales y sus máscaras de segmentación de caries (*ground truth*).


- Imágenes utilizadas: 100 imágenes
- División entrenamiento / validación: 80 % / 20 %
- Tamaño de entrada: 224×224 píxeles



Metodología

Arquitectura: U-Net con encoder VGG16 (transfer learning)

- **Encoder:** VGG16 preentrenado en ImageNet, congelado inicialmente.
- **Decoder:** bloques Conv2DTranspose + *skip connections* + convoluciones, entrenado desde cero.
- Capa de salida: convolución 1×1 con activación sigmoide.



Función de pérdida:


$$\mathcal{L} = \mathcal{L}_{BCE} + (1 - \text{Dice})$$

donde el Dice coefficient compensa el desbalance entre la clase “caries” y el fondo de la imagen


Entrenamiento en dos etapas:

1. **Transfer learning:** se entrena solo el decoder (encoder congelado).
2. **Fine-tuning:** se descongela el último bloque de VGG16 (block5) con tasa de aprendizaje reducida (10^{-5})

Resultados



Métrica	Antes fine-tuning	Después fine-tuning
Dice coefficient	0.2829	0.1623
IoU	0.1650	0.0885
Accuracy	0.9979	0.9988



Conclusiones

El fine-tuning no mejoró la segmentación: el Dice disminuyó de 0.283 a 0.162 y el IoU de 0.165 a 0.089. Las predicciones presentaron dificultades para delimitar con precisión los bordes de las lesiones. La elevada exactitud por píxel (99.88 %) debe interpretarse con cautela debido al desbalance entre fondo y caries. El reducido tamaño del conjunto de datos limita la generalización del modelo, por lo que se recomienda ampliar los datos y evaluar otras arquitecturas y estrategias de entrenamiento.

Referencias

Wang, X. et al. (2023). Multi-level uncertainty aware learning for semi-supervised dental panoramic caries segmentation. *Neurocomputing*, 540.

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *MICCAI*.

Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. *arXiv:1409.1556*.

Repositorio del dataset: <https://github.com/Zzz512/MLUA>